1. One-way ANOVA: C ~ F_1

Модель:

$$C_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$

где:

- μ — общее среднее,
- α_i — эффект уровня фактора F_1,
- ε_{ij} — случайная ошибка.

Проверяется гипотеза:

$$H_0 : \ \alpha_1 = \alpha_2 = \cdots = 0$$

то есть:

> средние значения C одинаковы для всех групп F_1.

Таблица:

Source	sum_sq	df	F	PR(>F)
C(F_1)	12.632018	2	28.219833	5.027300e-08
Residual	7.833509	35	NaN	NaN

Что такое sum_sq

Это суммы квадратов (Sum of Squares).

ANOVA раскладывает общую изменчивость данных:

$$SS_{Total} = SS_{Factor} + SS_{Residual}$$

Общая сумма квадратов

$$SS_{Total} = \sum_{i=1}^{N} (y_i - \bar{y})^2$$

где:

- y_i — наблюдение,
- $\bar{y}$ — общее среднее.

C(F_1) = 12.632018

Это межгрупповая сумма квадратов:

$$SS_{F_1} = \sum_{g=1}^{k} n_g(\bar{y}_g - \bar{y})^2$$

где:

- k — число групп,
- n_g — размер группы,
- $\bar{y}_g$ — среднее группы,
- $\bar{y}$ — глобальное среднее.

Смысл:

> насколько отличаются средние групп друг от друга.

Если групповые средние почти одинаковые → число маленькое.

Если группы сильно отличаются → число большое.

`Residual = 7.833509`

Это внутригрупповая сумма квадратов:

$$SS_E = \sum_{g=1}^{k} \sum_{i=1}^{n_g} (y_{ig} - \bar{y}_g)^2$$

Она измеряет:

> разброс внутри самих групп.

Проверка

$$SS_{Total} = 12.632018 + 7.833509 = 20.465527$$

Что такое `df`

`df` = degrees of freedom = степени свободы.

Для фактора

$$df_{F_1} = k - 1$$

У вас:

$$df = 2$$

значит уровней фактора:

$$k = 3$$

(например `R,S,T`).

Для остатка

$$df_E = N - k$$

У вас:

$$35 = N - 3$$

значит:

$$N = 38$$

Mean Squares

ANOVA дальше делит суммы квадратов на степени свободы.

Для фактора

$$MS_{F_1} = \frac{SS_{F_1}}{df_{F_1}} = \frac{12.632018}{2} = 6.316009$$

Для ошибки

$$MS_E = \frac{SS_E}{df_E} = \frac{7.833509}{35} = 0.2238145$$

F-статистика

$$F = \frac{MS_{Factor}}{MS_E}$$

Подставляем:

$$F = \frac{6.316009}{0.2238145} = 28.219833$$

Именно это число вы видите.

Что означает F

Если:

- различия между группами большие,
- а шум внутри групп маленький,

то F будет большим.

Если различия между группами сравнимы с шумом:

- $F \approx 1$.

У вас:

$$F = 28.22$$

Это очень большое значение.

PR(>F) = 5.027300e-08

Это p-value:

$$p = P(F_{random} \geq 28.22)$$

при условии, что:

- нулевая гипотеза верна,
- различий между группами нет.

Число:

$$5.027300 \times 10^{-8} = 0.000000050273$$

Это практически ноль.

Следовательно:

- вероятность случайно получить такой F ничтожна,
- нулевая гипотеза отвергается.

---

2. Two-way ANOVA: C ~ F_1 * F_2

Модель:

$$Y_{ijk} = \mu + \alpha_i + \beta_j + (\alpha\beta)_{ij} + \varepsilon_{ijk}$$

где:

- α_i — эффект F_1,
- β_j — эффект F_2,

- $(\alpha\beta)_{ij}$ — взаимодействие.

Таблица:

Source	sum_sq	df	F	p
C(F_1)	6.593679	2	33.318600	2.349342e-06
C(F_2)	1.851550	2	9.356091	4.554120e-03
C(F_1):C(F_2)	16.965026	4	42.863089	3.834397e-11
Residual	3.067417	31	NaN	NaN

Что изменилось

Теперь вариация раскладывается так:

$$SS_T = SS_{F_1} + SS_{F_2} + SS_{Interaction} + SS_E$$

C(F_1) = 6.593679

Это вклад только фактора F_1, после учета F_2.

C(F_2) = 1.851550

Это вклад фактора F_2.

C(F_1):C(F_2) = 16.965026

Это взаимодействие.

Смысл:

> влияние F_1 зависит от уровня F_2.

Например:

F_2	эффект F_1
A	маленький
B	большой

F_2	эффект F_1
C	отрицательный

Это и есть interaction.

Почему interaction огромный

$$16.965026$$

Это самая большая компонента вариации.

Значит:

> основная структура данных объясняется именно взаимодействием факторов.

Degrees of freedom

Для F_1

$$df = (3 - 1) = 2$$

Для F_2

$$df = (3 - 1) = 2$$

Для interaction

$$df = (a - 1)(b - 1)$$

У вас:

$$2 \times 2 = 4$$

Residual

$$df_E = N - ab$$

У вас:

$$31$$

Как считается F

Например для interaction:

Mean square interaction

$$MS_{Int} = \frac{16.965026}{4} = 4.2412565$$

Mean square error

$$MS_E = \frac{3.067417}{31} = 0.098949$$

F

$$F = \frac{4.2412565}{0.098949} = 42.863089$$

Почему F вырос

В однофакторной модели часть структуры данных попадала в residual.

После добавления interaction:

- residual резко уменьшился,
- объясненная вариация выросла.

Интерпретация p-values

F_1

$$p = 2.3 \times 10^{-6}$$

эффект очень значим.

F_2

$$p = 0.00455$$

тоже значим.

Interaction

$$p = 3.8 \times 10^{-11}$$

крайне сильное взаимодействие.

---

3. MANOVA

Модель:

$$[F_1_code,\ C] \sim F_2$$

Теперь зависимых переменных две:

- `F_1_code`
- `response_C`

Что делает MANOVA

ANOVA проверяет:

$$\mu_1 = \mu_2 = \dots$$

для одной переменной.

MANOVA проверяет:

совпадают ли векторные средние:

$$\boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = \dots$$

Почему понадобилось кодирование

`MANOVA` требует числовые зависимые переменные.

Поэтому:

category	code
R	0
S	1
T	2

Главная идея MANOVA

Есть:

- матрица внутригруппового разброса E,
- матрица межгруппового разброса H.

Wilks' lambda

Основная статистика:

$$\Lambda = \frac{|E|}{|E+H|}$$

где:

- $|\cdot|$ — determinant.

Интерпретация

Если группы одинаковы

Тогда:

- H маленькая,
- $\Lambda \approx 1$

Если группы сильно различаются

Тогда:

- H большая,
- $\Lambda \to 0$

Ваш результат

$$\Lambda = 0.4562$$

Это достаточно маленькое число.

Значит:

> F_2 существенно влияет на совместное распределение переменных.

Как получается F из Wilks

Wilks lambda преобразуется в приближенный F-критерий.

Идея:

$$F \sim \frac{(1-\Lambda)/\Lambda}{\text{noise}}$$

Точная формула длинная и зависит от:

- числа зависимых переменных,
- числа групп,
- df.

`statsmodels` использует стандартное преобразование Rao.

Num DF = 4

Число степеней свободы числителя.

Приблизительно:

$$p(g-1)$$

где:

- $p = 2$ зависимых переменных,
- $g = 3$ групп.

Получаем:

$$2(3-1) = 4$$

Den DF = 68

Степени свободы знаменателя. Они выводятся из аппроксимации распределения.

F Value = 8.1681

Это многомерный аналог ANOVA F-критерия.

Большое значение:

> групповые центры в многомерном пространстве различаются.

Pr > F = 0.0000

Это означает:

- p-value настолько мало, что при округлении стало 0.0000.

Другие статистики

Pillai's trace

$$V = \sum \frac{\lambda_i}{1 + \lambda_i}$$

Очень устойчивая статистика.

У вас:

$$0.5439$$

Hotelling-Lawley trace

$$T = \sum \lambda_i$$

где λ_i — собственные значения.

У вас:

$$1.1916$$

Roy's greatest root

Берется только максимальное собственное значение:

$$\theta = \max(\lambda_i)$$

У вас:

$$1.1914$$

Почему статистики разные

Все они измеряют:

> насколько далеко разнесены группы в многомерном пространстве,

но делают это разными способами:

- Wilks → через determinant,

- Pillai → через explained variance,
- Hotelling → через сумму eigenvalues,
- Roy → только через максимальное направление разделения.

Блок Intercept

`Intercept` проверяет гипотезу:

$$\mu = 0$$

для вектора средних.

Обычно он малоинтересен.

Поэтому основной результат — блок `F_2`.

Главное содержательное наблюдение

Ваши данные показывают:

1. `F_1` сильно влияет на `C`
2. `F_2` тоже влияет
3. interaction `F_1 × F_2` — очень сильное
4. MANOVA подтверждает многомерные различия между уровнями `F_2`